

実データで学ぶ人工知能講座 学習とは何か？

マシュー ホーランド

Matthew J. Holland

matthew-h@ar.sanken.osaka-u.ac.jp

大阪大学 産業科学研究所 助教

記憶は不思議

随意運動は学習と記憶の複雑で高度な機構を身近に感じる良い事例。




Figure: プリズム適応の現象.¹

¹北澤茂 (電総研・脳機能研究室) 資料より. 参考文献: Kitazawa et al. (1995).

記憶は不思議

ヒトの記憶には明確な方向性がある。これは多くの機械と異なる。

(A, B, C, D, ..., W, X, Y, Z)



Figure: カナダ国歌の楽譜.²

²Wikimedia で LilyPond より生成.

ハードウェアとソフトウェア

ヒトの学習ではこの両者が融合的に協働する。

言語獲得

どこまでが事前に組み込まれている？³

障害の影響

視覚障害と聴覚障害がそれぞれヒトの発達をどう左右する？

痛みのメカニズム

感覚のセンサー群と、「痛み」の生成・伝達・制御の仕組みの関係は？⁴

重要なキーワード：フィードバックと応答。

³Berwick and Chomsky (2016)

⁴Seymour (2019)

脳と心が機械である（という考え方）

機械は人工物であるから、理解は可能。脳と学習の仕組みもそうであって欲しい...

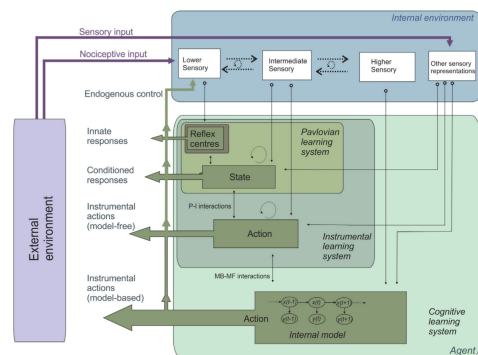


Figure: Seymour (2019) の強化学習的な痛みの仕組み。計算機で実装できそう。

一方、ヒトの脳と心を模倣する機械

- ▶ お客さんを案内する機械。
- ▶ 投げられたテニスラケットを瞬時につかめる機械。⁵
- ▶ ゲーム (チェス・囲碁・ファミコンなど) では驚異的な戦術を持つ機械。
- ▶ ダーツが下手な人を上手くさせる機械。⁶
- ▶ 痛みの機構に倣った学習アルゴリズムの開発。⁷

目的は何か？現時点の出来栄はどうか？そもそも数値化できるか？

⁵Aude Billard, ICML 2019 での招待講演。

⁶Obayashi et al. (2014)

⁷Ben Seymour, CiNet セミナー (2019/06/21)。

機械学習はデータに基づくフィードバックと応答

経験に相当するデータ

- ▶ 計測できないものは学習する機械の役に立たない。
- ▶ 正しく計測できたか？
- ▶ 正しいことを計測したか？← 大きな違い

学習の過程⁸

- ▶ 目的と今の状態を照らし合わせたフィードバックの構築
- ▶ 刻一刻変わりゆくフィードバック信号への応答方式
- ▶ 制約：どこまで事前に設計しておく？
- ▶ 不確実性：どこまで学習過程にゆだねる？

⁸統計的推論と情報と制御の関係を明快に展開した Wiener 教授の名著『Cybernetics』は必読。

機械学習システムの簡単な事例：映画の推薦

映画に対する個人の嗜好


- ▶ 定義することは難しい
- ▶ しかし映画を特徴づける要因はそこまで複雑ではない
- ▶ より正確な映画推薦 → レンタルが伸びる → 売上アップ！, と期待する。⁹

⁹公募型で1億円の賞金を出した Netflix Prize は有名。

機械学習システムの簡単な事例：映画の推薦

ユーザー側 (測定できない)

時代劇が好き
Brad Pitt のファンである
長い映画が好き
任侠映画が嫌い



システム側 (測定できる)

物語の年代設定
Brad Pitt の出演時間
上映時間
任侠映画であるか否か

幸い、左辺の嗜好はデータ (ユーザー履歴と評価など) から推し量ることができる。¹⁰

¹⁰賞金が支払われたのは 2009 年。その翌年には Kaggle が設立された。

事例に沿った学習の定式化

お金を貸す銀行から見た借り手の信用判定

- ▶ 経済活動と信頼性を表わす指標は山ほどある。
- ▶ しかし、将来のデフォルトの可能性を予測する魔法の公式は存在しない。

言い換えると、単なる演繹法は通用しない。

基本的な定式化

多数の顧客データ： $(x_1, y_1), \dots, (x_n, y_n)$

顧客情報： $x_i = (x_{i,1}, \dots, x_{i,d}) \in \mathcal{X} \subseteq \mathbb{R}^d$

不履行の有無： $y_i \in \mathcal{Y} = \{-1, +1\}$

データ例

年齢	39 歳
性別	男
年収	650 万
持ち家	なし
借金元本金額	200 万
現職勤続年数	2 年
債務不履行歴	なし
今回の不履行	あり

事例に沿った学習の定式化

基本的な定式化 (観測値)

データセット： $(x_1, y_1), \dots, (x_n, y_n)$

入力： $x_i = (x_{i,1}, \dots, x_{i,d}) \in \mathcal{X} \subseteq \mathbb{R}^d$

出力： $y \in \mathcal{Y} = \{-1, +1\}$

基本的な定式化 (確率変数)

データセット： $(X_1, Y_1), \dots, (X_n, Y_n)$

データ分布： $(X, Y) \sim P$

データ例

特徴 1	x_1
特徴 2	x_2
特徴 3	x_3
\vdots	\vdots
特徴 d	x_d
ラベル	y

事例に沿った学習の定式化：モデルの具体例

借り手の信用度を評価

指標 $x = (x_1, \dots, x_d)$ はたくさんあるが、信用度との関係性は自明ではない。

数値化した上で、重み係数で調整する

ある種の信用スコアを下記のように定義する。

$$\text{Score}(x; w) = \sum_{j=1}^d w_j x_j, \quad w = (w_1, \dots, w_d)$$

最終的な合否の決定はスコアに基づいて行う

- ▶ $\sum_{j=1}^d w_j x_j \geq w_0$ ならば「合格」と判断。
- ▶ $\sum_{j=1}^d w_j x_j < w_0$ ならば「不合格」と判断。

事例に沿った学習の定式化：モデルの具体例

モデルの設定と働き

- ▶ もし $x_j \geq 0$ が「信用に値する」ならば $w_j > 0$ にすべき.
- ▶ もし $x_j \geq 0$ が「信用を損なう」ならば $w_j < 0$ にすべき.
- ▶ 正負関係なく x_j が信用度に寄与するほど $|w_j|$ を大きくすべき.

モデルは候補の集合

(左) 一候補. (右) 候補の全体. これはパーセプトロンと呼ばれる.¹¹

$$h(x) = \text{sign} \left(\sum_{j=1}^d w_j x_j - w_0 \right), \quad \mathcal{H} = \left\{ x \mapsto \text{sign}(w^\top x - w_0) : (w, w_0) \in \mathbb{R}^{d+1} \right\}$$

¹¹ 異名は多数あるが, この名称は Frank Rosenblatt の造った種々の「学習する機械」にちなんだもの. これを抽象化し, 理論的に学習能力を解析した Minsky and Papert (1969) によってさらに有名になった.

事例に沿った学習の定式化：アルゴリズムの具体例

モデルとアルゴリズム

- ▶ 持っている情報と, 達成したい目的を結びつけるのが**モデル**である.¹²
- ▶ 合理的なモデルがあっても, 無数の選択肢がある.
- ▶ そのなかから良い候補を選ぶのが**学習アルゴリズム**である.

¹² 魔法の公式は存在しないが, モデルを決めるということは, 暗示的にそのような公式があることを仮定しているとも捉えられる.

事例に沿った学習の定式化：アルゴリズムの具体例

パーセプトロンの幾何学的な解釈は「空間を**平面で分けている**」という簡明なもの.




Figure: 二つの候補を上図で示している. それぞれが何を重視している?

事例に沿った学習の定式化：アルゴリズムの具体例

パーセプトロンの幾何学的な解釈は「空間を**平面で分けている**」という簡明なもの.

重みの正負と閾値の影響を图示して考えると良い.

$$\sum_{j=1}^d w_j x_j \geq w_0$$

右図では $d = 2$ なので, **平面を線で分ける** ことになっている.

高次元の場合でも同様に二つの領域に分離される.




Figure: 重み係数の正負について考えてください.

事例に沿った学習の定式化：アルゴリズムの具体例

パーセプトロンの幾何学的な解釈は「空間を平面で分けている」という簡明なもの。

重みの正負と閾値の影響を図示して考えると良い。

$$\sum_{j=1}^d w_j x_j \geq w_0$$

右図では $d = 2$ なので、平面を線で分けることになっている。

高次元の場合でも同様に二つの領域に分離される。




Figure: 重み係数の正負について考えてください。

事例に沿った学習の定式化：アルゴリズムの具体例

パーセプトロンの幾何学的な解釈は「空間を平面で分けている」という簡明なもの。

重みの正負と閾値の影響を図示して考えると良い。

$$\sum_{j=1}^d w_j x_j \geq w_0$$

右図では $d = 2$ なので、平面を線で分けることになっている。

高次元の場合でも同様に二つの領域に分離される。





Figure: 重み係数の正負について考えてください。

事例に沿った学習の定式化：アルゴリズムの具体例

データに語らせる


「簡単だ。線を引けば良い！」という直感は機械に通じない。データに頼るべし。



事例に沿った学習の定式化：アルゴリズムの具体例


データに語らせる

「簡単だ。線を引けば良い！」という直感は機械に通じない。データに頼るべし。



事例に沿った学習の定式化：アルゴリズムの具体例


適当に初期値を選ぶ. 全問正解になるまで, 一点ずつラベルづけの改善を求めていく.



以下では $h_{(t)}(x) := \text{sign}(w_{(t)}^T x)$ と表記する.

事例に沿った学習の定式化：アルゴリズムの具体例

適当に初期値を選ぶ. 全問正解になるまで, 一点ずつラベルづけの改善を求めていく.




以下では $h_{(t)}(x) := \text{sign}(w_{(t)}^T x)$ と表記する.

パーセプトロン学習則 (PLA)

- 1: initialize $t \leftarrow 0$, $w_{(0)}$ randomly.
- 2: initialize $\mathcal{I} \leftarrow \{1, \dots, n\}$.
- 3: **while** $|\mathcal{I}| > 0$ **do**
- 4: $\mathcal{I} \leftarrow \{i : h_{(t)}(x_i) \neq y_i\}$
- 5: randomly select $k \in \mathcal{I}$.
- 6: $w_{(t+1)} \leftarrow w_{(t)} + y_k x_k$
- 7: $t \leftarrow t + 1$
- 8: **return** $w_{(t)}$

事例に沿った学習の定式化：アルゴリズムの具体例

適当に初期値を選ぶ. 全問正解になるまで, 一点ずつラベルづけの改善を求めていく.




以下では $h_{(t)}(x) := \text{sign}(w_{(t)}^T x)$ と表記する.

パーセプトロン学習則 (PLA)

- 1: initialize $t \leftarrow 0$, $w_{(0)}$ randomly.
- 2: initialize $\mathcal{I} \leftarrow \{1, \dots, n\}$.
- 3: **while** $|\mathcal{I}| > 0$ **do**
- 4: $\mathcal{I} \leftarrow \{i : h_{(t)}(x_i) \neq y_i\}$
- 5: randomly select $k \in \mathcal{I}$.
- 6: $w_{(t+1)} \leftarrow w_{(t)} + y_k x_k$
- 7: $t \leftarrow t + 1$
- 8: **return** $w_{(t)}$

事例に沿った学習の定式化：アルゴリズムの具体例

適当に初期値を選ぶ. 全問正解になるまで, 一点ずつラベルづけの改善を求めていく.



以下では $h_{(t)}(x) := \text{sign}(w_{(t)}^T x)$ と表記する.

パーセプトロン学習則 (PLA)


- 1: initialize $t \leftarrow 0$, $w_{(0)}$ randomly.
- 2: initialize $\mathcal{I} \leftarrow \{1, \dots, n\}$.
- 3: **while** $|\mathcal{I}| > 0$ **do**
- 4: $\mathcal{I} \leftarrow \{i : h_{(t)}(x_i) \neq y_i\}$
- 5: randomly select $k \in \mathcal{I}$.
- 6: $w_{(t+1)} \leftarrow w_{(t)} + y_k x_k$
- 7: $t \leftarrow t + 1$
- 8: **return** $w_{(t)}$

手は $\{-1, 1\}$ で手は理想の超平面での分離

結果？ この時の $y_k = -1$? \Rightarrow

事例に沿った学習の定式化：アルゴリズムの具体例

適当に初期値を選ぶ. 全問正解になるまで, 一点ずつラベルづけの改善を求めていく.




以下では $h_{(t)}(x) := \text{sign}(w_{(t)}^T x)$ と表記する.

パーセプトロン学習則 (PLA)

- 1: initialize $t \leftarrow 0$, $w_{(0)}$ randomly.
- 2: initialize $\mathcal{I} \leftarrow \{1, \dots, n\}$.
- 3: **while** $|\mathcal{I}| > 0$ **do**
- 4: $\mathcal{I} \leftarrow \{i : h_{(t)}(x_i) \neq y_i\}$
- 5: randomly select $k \in \mathcal{I}$.
- 6: $w_{(t+1)} \leftarrow w_{(t)} + y_k x_k$
- 7: $t \leftarrow t + 1$
- 8: **return** $w_{(t)}$

事例に沿った学習の定式化：アルゴリズムの具体例

適当に初期値を選ぶ. 全問正解になるまで, 一点ずつラベルづけの改善を求めていく.





以下では $h_{(t)}(x) := \text{sign}(w_{(t)}^T x)$ と表記する.

パーセプトロン学習則 (PLA)

- 1: initialize $t \leftarrow 0$, $w_{(0)}$ randomly.
- 2: initialize $\mathcal{I} \leftarrow \{1, \dots, n\}$.
- 3: **while** $|\mathcal{I}| > 0$ **do**
- 4: $\mathcal{I} \leftarrow \{i : h_{(t)}(x_i) \neq y_i\}$
- 5: randomly select $k \in \mathcal{I}$.
- 6: $w_{(t+1)} \leftarrow w_{(t)} + y_k x_k$
- 7: $t \leftarrow t + 1$
- 8: **return** $w_{(t)}$

事例に沿った学習の定式化：アルゴリズムの具体例



PLA は単純だが実に合理的

平面を決める重みベクトルと入力データのなす「角度」を考える.

以下の等式が成り立つ.


$$\langle w_{(t+1)}, x_k \rangle = \langle w_{(t)}, x_k \rangle + y_k \langle x_k, x_k \rangle$$

したがって, 角度を小さくすべきときは小さくし, 大きくすべきときは大きくする.¹³

事例に沿った学習の定式化：アルゴリズムの具体例

PLA の収束について

- ▶ 線型分離可能であれば, 必ず有限回の更新で終了する (上界までわかる).
- ▶ もっとも簡明な証明は Novikoff (1963) であろう.
- ▶ 1962 の時点でもすでに Rosenblatt を筆頭に, 色々な人によって何度も証明され, 当時の関心の高さが窺える.¹⁴



まとめ

学習とは何か

- ▶ ヒトの記憶と学習の仕組み
- ▶ 脳を機械として捉える脳科学
- ▶ 脳を究極の機械として捉える情報工学

機械学習の初歩

- ▶ 典型的な事例
- ▶ 教師あり学習課題の定式化
- ▶ モデルとアルゴリズムの概念
- ▶ パーセプトロン学習アルゴリズム

※関心のある方は付属の[演習課題](#)にも取り組んでみてください。

参考文献

- Berwick, R. C. and Chomsky, N. (2016). *Why Only Us: Language and Evolution*. MIT Press.
- Kitazawa, S., Kohno, T., and Uka, T. (1995). Effects of delayed visual information on the rate and amount of prism adaptation in the human. *Journal of Neuroscience*, 15(11):7644–7652.
- Minsky, M. and Papert, S. A. (1969). *Perceptrons: An Introduction to Computational Geometry*. Reprinted in 2017 by MIT Press.
- Novikoff, A. B. J. (1963). On convergence proofs for perceptrons. Technical report, Stanford Research Institute, Menlo Park California.
- Obayashi, C., Tamei, T., and Shibata, T. (2014). Assist-as-needed robotic trainer based on reinforcement learning and its application to dart-throwing. *Neural Networks*, 53:52–60.
- Seymour, B. (2019). Pain: a precision signal for reinforcement learning and control. *Neuron*, 101(6):1029–1041.